

● GPT-4o    ■ DeepSeek-R1    ◆ Qwen2.5 72B    ▲ Llama 3 70B    - - - Mean

